



山东大学
SHANDONG UNIVERSITY

毕业论文（设计）

论文（设计）题目： 6G 通感算一体化背景下波束成形设计研究

姓 名	夏宇晨
学 号	202000120048
学 院	信息科学与工程学院
专 业	通信工程
年 级	2020 级
指导教师	张文胜副教授

2024 年 12 月 26 日

摘 要

随着第六代移动通信系统（The Sixth Generation Mobile Communication Systems, 6G）的快速发展，极高的数据传输速率、超低延迟和超高可靠性、全球性网络整合、更广范围覆盖以及更大链接密度的需求日益增加。在面对这些需求时，传统的基于混合波束成形（Hybrid Beamforming）的算法已经逐渐无法满足这些。因此，需要引入一些新的方法，对原有的波束成形设计进行改善，而随着深度学习等人工智能技术的发展，引入基于神经网络的方法成为了解决方案之一。在 6G 通感算一体化背景下，本文通过基于注意力机制的波束成形 Transformer 网络（Beamforming Transformer Network, BFTN）模型对原有的波束成形神经网络（Beamforming Neural Network, BFNN）模型进行改善，从而实现波束成形设计的改进。

本论文首先介绍了 6G 通信技术的背景和相应波束成形技术的背景和发展。同时，深度学习技术作为改进的方法，相关的发展历程也会被提及与介绍。

随后，本文详细阐述了通过基于注意力机制的 BFTN 模型的架构和工作原理。BFTN 模型利用了注意力机制的思想，通过自适应加权对输入信号进行处理，实现更准确和精细的波束成形。在学习波束权重时，BFTN 模型在学习波束权重时考虑了输入信号的相关性，进一步提高了波束成形的性能。

在完成对 BFTN 模型的构建后，本文从多个维度对 BFTN 模型进行了性能的评估。评估结果表明 BFTN 模型在波束成形设计方面相较于现有的波束成形设计取得了显著的改进。同时，BFTN 模型还展现出较好的适应性和泛化能力，对于多种不同的通信场景下的信道模型，均展现出优秀的性能。这些结果为 6G 的发展提供了有益参考和指导。

文章最后对通过 BFTN 模型改进波束成形设计这一方法进行了总结，并相应给出了对于 BFTN 模型可能存在的一些改进方向，同时本文也对相关技术的发展以及在通信中的应用进行展望。

总而言之，BFTN 模型有望在 6G 中发挥重要作用，人工智能技术赋能传统通信领域的方法可以被广泛地用于与 6G 关键技术相结合，为未来移动通信的发展带来新的突破。

关键词：6G；波束成形；通感算一体化；注意力机制；BFTN

ABSTRACT

With the rapid development of the Sixth Generation Mobile Communication Systems (6G), there is an increasing demand for extremely high data transmission rates, ultra-low latency, ultra-high reliability, global network integration, wider coverage, and higher link density. Traditional algorithms based on Hybrid Beamforming are gradually becoming insufficient to meet these demands. Therefore, the need arises to introduce new methods to improve the existing beamforming designs. With the advancement of deep learning and other artificial intelligence technologies, the introduction of neural network-based methods has become one of the solutions. In the context of 6G integrated sensing, communication and computation, this paper proposes an improvement to the existing Beamforming Neural Network (BFNN) model by introducing the Beamforming Transformer Network (BFTN) model based on the attention mechanism, aiming to enhance the beamforming design.

This paper first introduces the background and development of 6G communication technology and the corresponding beamforming techniques. Additionally, the development process of deep learning technology as an improvement method will also be mentioned and introduced.

Subsequently, this paper elaborates on the architecture and working principles of the BFTN network based on the attention mechanism. The BFTN network incorporates the idea of attention mechanism, processing the input signals through adaptive weighting to achieve more accurate and precise beamforming. During the learning of beam weights, the BFTN network considers the correlation of input signals, further improving the performance of beamforming.

After completing the construction of the BFTN model, this paper evaluated the performance of the BFTN model from multiple dimensions. The evaluation results demonstrated significant improvements of the BFTN model in beamforming design compared to existing beamforming designs. Moreover, the BFTN model exhibited good adaptability and generalization capabilities, showcasing excellent performance across various commu-

nication scenarios and channel models. These findings provide valuable references and guidance for the development of 6G.

In conclusion, this article summarized the approach of improving beamforming design through the BFTN model and highlighted potential directions for further enhancements. Additionally, the paper provided insights into the development of related technologies and their applications in communication.

In summary, the BFTN model holds great promise in the context of 6G and the application of artificial intelligence techniques in traditional communication fields can be widely combined with key 6G technologies, paving the way for new breakthroughs in the future of mobile communication.

Key Words: 6G, Beamforming, Integrated sensing, communication and computation, Attention mechanism, BFTN

目 录

第一章 绪论	1
1.1 研究背景	1
1.2 国内外研究现状	3
1.2.1 波束成形研究现状	3
1.2.2 深度学习研究现状	5
1.3 论文内容安排	7
第二章 系统与模型	9
2.1 通信系统模型	9
2.2 深度学习网络	12
2.2.1 波束成形神经网络	13
2.2.2 波束成形 Transformer 网络	15
第三章 数据分析	20
3.1 仿真	20
3.2 结果分析	22
第四章 总结与展望	28
4.1 总结	28
4.2 展望	28
参考文献	30
致 谢	33

第一章 绪论

1.1 研究背景

伴随着通信应用的发展，通信技术也随着一代代更新迭代。从最初的第一代移动通信系统开始，每一代的升级往往会带来更高的频率、更宽的带宽和更高的数据传输速率。2019 年，第五代移动通信系统（The Fifth Generation Mobile Communication Systems, 5G）开始进入商用。5G 利用大规模多输入多输出（Multiple-Input Multiple-Output, MIMO）^[1]、波束成形^[2]、超密集网络（Ultra-Dense Networking）^[3]、蜂窝边缘计算（Mobile Edge Computing）^[4]、网络切片（Network Slicing）^[5]等技术，实现了基于毫米波（mmWave）的通信，其峰值速度可以达到 20Gbps。

虽然 5G 相较于之前的移动通信系统已经取得了巨大的改进，但面对飞速发展的现实，仍面临着许多困难与挑战。因此对于新一代的移动通信系统，除了要实现更高的频率、更大的带宽和更高的数据传输速率，这些 5G 中存在的问题都需要在将要到来的第六代移动通信系统（The Sixth Generation Mobile Communication Systems, 6G）中被解决。

相较于 5G 中使用的毫米波，6G 通过太赫兹通信^[6]的方式来实现更高效的数据传输。太赫兹的频率在 100GHz 至 10THz 之间，相较于当前使用的毫米波频段，太赫兹频段具有更高的带宽和数据传输速率。太赫兹频段的高频率还使他还具备了较高的穿透能力和低的信号衰减，从而信号在传输过程中可以有效减少损耗，一定程度上降低受到其他信号的干扰。

受到波段的限制，5G 选择的毫米波频段虽然具有较高速率但衍射能力较弱，传播距离短，无法向较远的地方传播，这使得对于人烟稀少的陆地以及海洋区域未被覆盖。6G 希望通过结合卫星通信、航空通信、地面通信、海洋通信形成空天地一体化，完成对通信网络资源的整合，实现全球覆盖。

超可靠低延迟通信（Ultra-Reliable and Low-Latency Communications, URLLC）^[7]作为 5G 的一个重要特性，在工业自动化、远程医疗、智能交通、虚拟现实和增强现实领域都有着重要的表现。但是，基于毫米波的 URLLC 并不能完全满足一些高速低延迟领域的要求比如智能驾驶。6G 将会对可靠性和低延迟提出进一步的要求^[8-9]。

在 6G 通信背景下，通感算一体化是一个重要的发展方向。随着物联网、人工智能和边缘计算的快速发展，6G 通信系统被定义为一种可以感知、理解和自适应环境的智能网络^[10]。通信感知计算一体化作为 6G 一个公认的关键的技术趋势，将通信、感知和计算融合在一起，为 6G 通信带来了巨大的潜力和机遇。

在传统模式下，通信、计算和感知是分离的独立模块。通信模块负责数据的传输和通信连接，计算模块处理接收到的数据进行分析和计算，感知模块负责数据的采集和传感器的控制。在这种模式下，存在着一些问题。

显而易见的，分离运行直接导致的一个问题就是高延迟。如果向一个未知用户先定位后通信，至少会存在感知定位和通信的两个处理时间，在通感一体化中，如果能在感知定位的过程中直接同步进行通信，将大大减少时延，提高通信的效率，更符合 URLLC 的趋势。

在传统模式下，雷达等感知设备需要单独的频段进行感知。随着对感知目标需求如精准探测和跟踪的逐步被提出，感知设备所占用的频段也逐渐向高频扩展。目前，大量毫米波雷达已进入实用，而毫米波频段作为 5G 的核心通信频段，这使得频谱资源更加紧张。实现通感算一体化将有利于解决频谱资源紧张的问题。

通感算一体化后，通信感知利用同样的频段，这也意味着可以复用实现通信、感知的射频（Radio Frequency, RF）天线。这使得在进行实际部署使用阶段，能大大减少基站部署的成本，在相同的预算下，可以覆盖更广的区域，有助于实现更广阔更优质的全球覆盖。

而在通感算一体化进程中，无论是通信还是感知，都无法绕过波束成形。传统无线通信系统^[11]中，信号以均匀的方式辐射，导致信号受到多径衰落、干扰和能量浪费等问题。而波束成形技术可以通过调整天线阵列中各个天线的相位和间距来形成一个或多个定向的波束，从而实现信号的有指向性，而非传统以同心圆的方式进行扩散。在感知设备中，通过波束成形调整感知范围，实现对指定目标方向的精细探测，有助于提高感知精度：在通信中，通过波束成形，能够将有限的能量集中在指定方向，减少无效的能量逸散，提高吞吐量、频谱效率从而提高信号的传输效率和可靠性。因此，波束成形作为一种关键技术，在 6G 通信中发挥着重要作用。

在 6G 中，因为要提供比当前 5G 系统更高的数据传输速率和容量，这对信号传输的抗干扰性和频谱效率提出了更高的要求。对于波束成形设计而言，需要更高的准确度。而对于 6G 通信系统将支持高速移动的终端设备的需求，相应的波束成形设计方法还需要具备计算量低和处理变换速度快的特征。

目前,在 5G 的大规模 MIMO 中使用的波束成形实现是混合波束成形 (Hybrid Beam-forming, HBF)^[12-13]方法。HBF 具有较高的硬件复杂性,通过同时使用模拟子阵列和数字子阵列实现波束成形直接导致了整个系统具有较高的复杂性、成本和功耗。在 6G 面向的场景中,延迟和能耗远远达不到需求。

随着人工智能 (Artificial Intelligence, AI) 的发展和运用, AI 在通信中的应用作为 6G 的一个鲜明特征为波束成形的改进提供了方案。通过结合相应的深度学习技术,利用大量廉价的基础运算单元来替代复杂的数字模拟子阵列实现,降低了部署成本的同时,也降低了能耗与延迟,为实现满足 6G 需求的波束成形设计提供了可能。

1.2 国内外研究现状

1.2.1 波束成形研究现状

最初,波束成形技术的出现并不是在通信领域,而是在雷达系统中。20 世纪 40 年代,雷达开始出现,用于探测空中和海上单位,最早采用的方式通常是仅仅使用单个天线来进行发射和接收信号,信号以天线为中心,均与向外侧辐射。这种方式在目标检测,尤其是定位方面存在着巨大的限制,在多目标或者存在电磁干扰情况下极其容易无法发挥作用。为了解决这些问题,研究人员开始尝试使用多个天线组成的天线阵列进行波束成形。

受到技术条件的限制,最早的波束成形全部通过模拟电路的方式实现,成本较高,而在实际应用场景中需要根据实际情况手动调节,天线的形状和相位相对固定,调节需要大量的时间成本,对变化环境的适应力差。

伴随着数字电路的发展,部分数字电路原件的引入使得数字波束成形的方式出现,这也是现代波束成形的主流调节方式。随着数字信号处理的一些算法的提出,在发送端可以对输入的信号实现一些复杂的操作如加权调相,从而使得信号在发送时能具有更好的指向性与抗干扰性。同时,数字化的电路极大简化了电路结构,为更低成本的波束成形提供了可能。

随着通信技术的发展,波束成形也被引入到通信中。波束成形技术最早在通信中的应用可以追溯到第一代移动通信系统,此时,波束成形技术还处于模拟波束成形的阶段,因为对性能的改善并不太明显,所以虽然对于通信的质量和距离有着一定改善,但是并没有被作为主要的通信技术被研究。数字波束成形的发展展现了波束成形在波束的控制和优化方面的巨大作用,在第二代和第三代通信系统中,波束成形技术被广泛部署在基

站端，用于扩大覆盖范围和通信质量，提高系统的容量、发射的频谱效率和信号的抗干扰能力。

在第四代移动通信系统和 5G 中，随着 MIMO 的广泛应用，波束成形也被广泛使用来提高系统的容量。在 5G 和将要到来的 6G 中，随着使用的载波频率的提升，虽然这些频段可以使得通信具有更大的带宽，拥有更高的传输速率，但随之而来的更差的传输特性，这些信号更加容易受到路劲衰落的影响，更容易受到其他信号的干扰，更容易被障碍物所阻碍，因此波束成形技术也更加受到重视和挑战。

而根据波束成形方式的不同，大致可以分为三种成形方式：直向波束成形^[14-15]、扇区波束成形^[16-17]以及自适应波束成形^[18-19]。

最早出现波束成形方案的是直向波束成形。通过调整天线阵列中不同天线的相位和增益，使得发送的信号能量能聚焦在特定方向上。但是由于直向波束成形的主要目标是在垂直方向上实现高增益和指向性，这使得它在水平方向上的覆盖范围较小。同时在多径传播环境中，使用直向波束成形成容易受到干扰和衰落效应的影响，对于多用户场景下的干扰抑制能力有限。为了解决直向波束成形的部分问题，扇区波束成形技术被引入。扇区波束成形将天线阵列分为多个扇区，每个扇区形成一个波束，可以覆盖更广泛的用户区域。扇形波束成形引入了水平方向上的指向性，将信号能量集中在一个扇形区域内，同时保持垂直方向上的增益，解决了直向波束成形中的水平覆盖限制问题。但是扇形的引入也带来了新的问题，在多用户场景下，不同用户的扇形波束可能会相互干扰。多个基站或设备同时采用扇形波束成形时，它们的之间的波束难免会相互重叠，从而导致波束之间相互干扰，这个问题对于移动的用户尤为显著。伴随着用户的移动，极易容易产生扇区间的切换，从而导致信号质量发生下降甚至通信发生中断，这对移动用户的跟踪和定位提出了新的要求。为了解决这一问题并进一步提高波束成形性能，自适应波束成形技术被提出。自适应波束成形利用用户的反馈信息以及信道状态信息在波束成形过程中来动态调整波束权重和相位，从而适应不同的信道条件和用户位置。相较前两种波束成形方式，自适应波束成形具有较好的抗干扰能力和适应性，也有着较大系统的容量和覆盖范围。然而，自适应算法的计算复杂度较高，需要实时的信道估计和反馈机制，对于快速移动的用户跟踪和变化的信道条件不能很好做出反应。

在通感算一体化背景下，波束成形的研究变得更加复杂和多样化^[20]。通过感知环境中的用户位置、信道状态和其他无线节点的信息，可以更准确地设计和优化波束成形方案。同时，利用深度学习在波束成形中的应用^[21-22]也成为研究的热点之一。

1.2.2 深度学习研究现状

深度学习是一种人工智能领域中重要的技术手段，其核心思想是通过构建和训练多层神经网络模型来学习输入数据的特征表示和输入输出的映射关系。然后将训练好的模型作为一种工具，实现对输入的处理。在波束成形中，深度学习可以用于信号预处理^[23]、信道估计^[24]、波束权重优化等波束成形设计中的关键环节。通过用深度学习算法来替换原有的处理，从而可以实现更快更精确的波束成形，提升整体通信系统的性能。

尽管深度学习的起源可以追溯到上世纪四五十年代的神经网络模型^[25]，但是受限于当时计算工具的落后，计算速度无法满足计算的需求，因此，相关方法在一开始并没有取得较大的进展。随着时间进入到 20 世纪 80 年代和 90 年代，深度学习逐渐崭露头角。多层感知机（Multilayer Perceptron）^[26]和反向传播算法（Back-propagation）^[27]的提出，使得模型不再局限于手动调节比较参数，模型可以通过反向传播损失误差信号来自动调整网络中的权重，为训练提供了可能。

进入 21 世纪以来，伴随着集成电路的复杂化和计算机的高速发展，充足的计算机算力为训练使用神经网络来实现相关数据处理提供了可能。标志着深度学习开始成为一种高效工具的是 2012 年 AlexNet^[28]模型等一系列卷积神经网络（Convolutional Neural Networks, CNN）的出现。AlexNet 首次采用了多层卷积层和池化层的结构，在 ImageNet 图像识别的挑战赛中取得了显著的优势，引起了广泛的关注。在传统的 CNN 中，为了提高模型准确性，通常性的做法是增加网络层数。一个典型的例子是视觉几何组网络（Visual Geometry Group Network, VGGNet）^[29]。VGGNet 通过小卷积核多层的方式实现了对输入的细节信息的高效利用。但随着网络深度的增加，准确性提高的效果越来越弱，甚至出现准确性的降低的网络退化问题，梯度消失以及梯度爆炸的问题被人们关注到。为了解决这一问题，ResNet^[30]被提出，通过建立跨层之间的联系，使得在训练过程中可以动态舍弃部分反向优化的层，确保随着层数的增加，模型的准确性可以得到正向的增益。

深度学习另一个大的发展方向是循环神经网络（Recurrent Neural Networks, RNN）^[31]。CNN 仅仅会针对单次输入数据自身内部的信息进行提取和处理，RNN 更加关注于序列输入之间的变化关系，从而实现基于输入关系的推导预测。Elman 网络^[32]首次提出通过引入循环连接，使得网络模型能够在处理序列输入数据的时候能够考虑上一时刻输入的数据。长短期记忆（Long Short-Term Memory）^[33]模型的提出是 RNN 发展过程中的一个里程碑，它通过引入门控循环单元（Gated Recurrent Unit）等方式解决了传统 RNN

中的梯度消失和梯度爆炸问题，使得 RNN 在语音识别^[34]、机器翻译^[35]等任务中取得了重大突破。

RNN 在机器翻译领域的重大突破为机器理解文本提供了先决条件，再加上机器翻译领域中用于神经机器翻译的注意力机制的提出^[36]的提出，Transformer^[37]的基础被建立。Transformer 利用注意力机制能够很好的提取输入之间与输入本身的高维特征，能够轻易的抓取输入的联系，为自然语言处理（Natural Language Processing）领域了强有力的解决方案，因此成为了现在大模型的基础。目前而言，绝大多数的大模型都依据 Transformer 构建。

Transformer 模型主要由两个部分组成，一个是编码器（Transformer-Encoder）部分，一个是解码器（Transformer-Decoder）部分。Transformer-Encoder 作为 Transformer 的编码器，用于对输入信息的分析。一个经典由编码器构成的模型就是 Transformer 的双向编码器表示（Bidirectional Encoder Representation from Transformers, BERT）^[38]模型。BERT 模型基于 Transformer 的编码器部分构建，通过使用多个编码器结构的模块，对于输入的信息进行有效的提取和理解，从而能有效捕捉输入的内在逻辑关系，因此被主要用于理解和表示文本等输入信息。Transformer-Decoder 作为信息的解码器，通过给定的现有信息与获得的逻辑与联系，依据规则实现预测输出，具有很强的自回归生成能力。通过解码器构建的一个典型模型与应用便是生成预训练（Generative Pre-Trained, GPT）模型。GPT 模型主要使用了 Transformer 架构中的解码器部分，通过利用解码器的自回归生成能力，实现对可能的下文实现预测，并通过不断自我调用的方式实现生成连贯并且具有上下文关联的文本。凭借出色的文本生成能力，GPT 系列模型在语言生成任务中取得了巨大的成功，ChatGPT 便是基于 GPT 模型实现语言生成任务的应用之一。

近几个月以来，一种新的名叫 mamba 的架构被提出^[39]。其作者声称基于 mamba 架构的模型其具有远超 Transformer 的性能，但一些学者认为其实验以及仿真不够充分，相应的理念仍等待被验证与改进，实际的效果仍然有待考究。但这并不妨碍 mamba 架构以及各种基于 mamba 架构的模型成为目前的热门研究方向之一。为了确保模型对于当下解决方案的改进效果以及对问题的进一步解决，本文仍选择基于 Transformer 的内在逻辑的方式来构建模型，并且这并不意味着 mamba 架构不能被用于后续基于该问题的改进。

1.3 论文内容安排

本文以 6G 通感算一体化背景下波束成形设计问题为核心，研究了基于注意力机制的深度学习改进的波束成形方案。本文的目标是在有限资源和低延迟的情况下，建立一个具有良好鲁棒性的深度学习波束成形自适应调整网络。在本文中，一个全新的基于注意力机制的波束成形 Transformer 网络 (Beamforming Transformer Network, BFTN) 模型被提出，用于对原有的波束成形神经网络 (Beamforming Neural Network, BFNN) 模型进行改善，从而实现波束成形设计的改进。全文共分为四个章节，具体每个章节所阐述探究的内容如下：

第一章详细阐述了本文的研究背景与实际意义，并且详细介绍了目前波束成形技术和深度学习技术的发展历程与研究现状。同时，针对于目前研究现状，指出了当下波束成形设计面临的挑战、解决问题的主要方法以及将使用什么样的神经网络架构来实现对目前波束成形设计的改进。

根据实际内容，第二章主要分为了两个部分。一个部分是通信系统模型，另一个部分是深度学习网络。在通信系统模型部分中，对涉及到的波束成形技术原理进行了相应的介绍，并随后介绍了本文包含了波束成形的局部通信系统建模。在深度学习网络中，两个模型会被介绍，一个是现有的 BFNN 模型，另一个是 BFTN 模型。在介绍 BFNN 模型中会顺带对使用到的深度学习原理概念进行阐述；在介绍 BFTN 模型时，将会详细阐述模型构建所基于的原理、模型模块设计所运用的思路、各个组件模块内部的结构以及整体 BFTN 模型数据处理的流程。

第三章中将首先介绍模型所使用的数据集，模型所部署的环境。随后，相较于深度学习中普遍使用的均方差函数，一个专门在本文所构建的通信环境背景下直接衡量模型的指标被设计与定义。通过这个指标，在环境噪声相对值和通信信道建模两个方面，所设计构建的模型 BFTN 被与 BFNN 进行比较。同时，根据测试的结果，初步的结论也将被给出。

第四章对全文内容进行了简要的总结，同时也归纳分析了本文的一些模型设计思路与模型构造方式对实际问题的解决做出的贡献。部分工作存在的局限性也在这部分展开了有限的讨论。最后依据模型存在的局限性以及目前其他相关研究的进展给出可能的改进与发展方向。

文章的大致结构可以由图1.1表示。

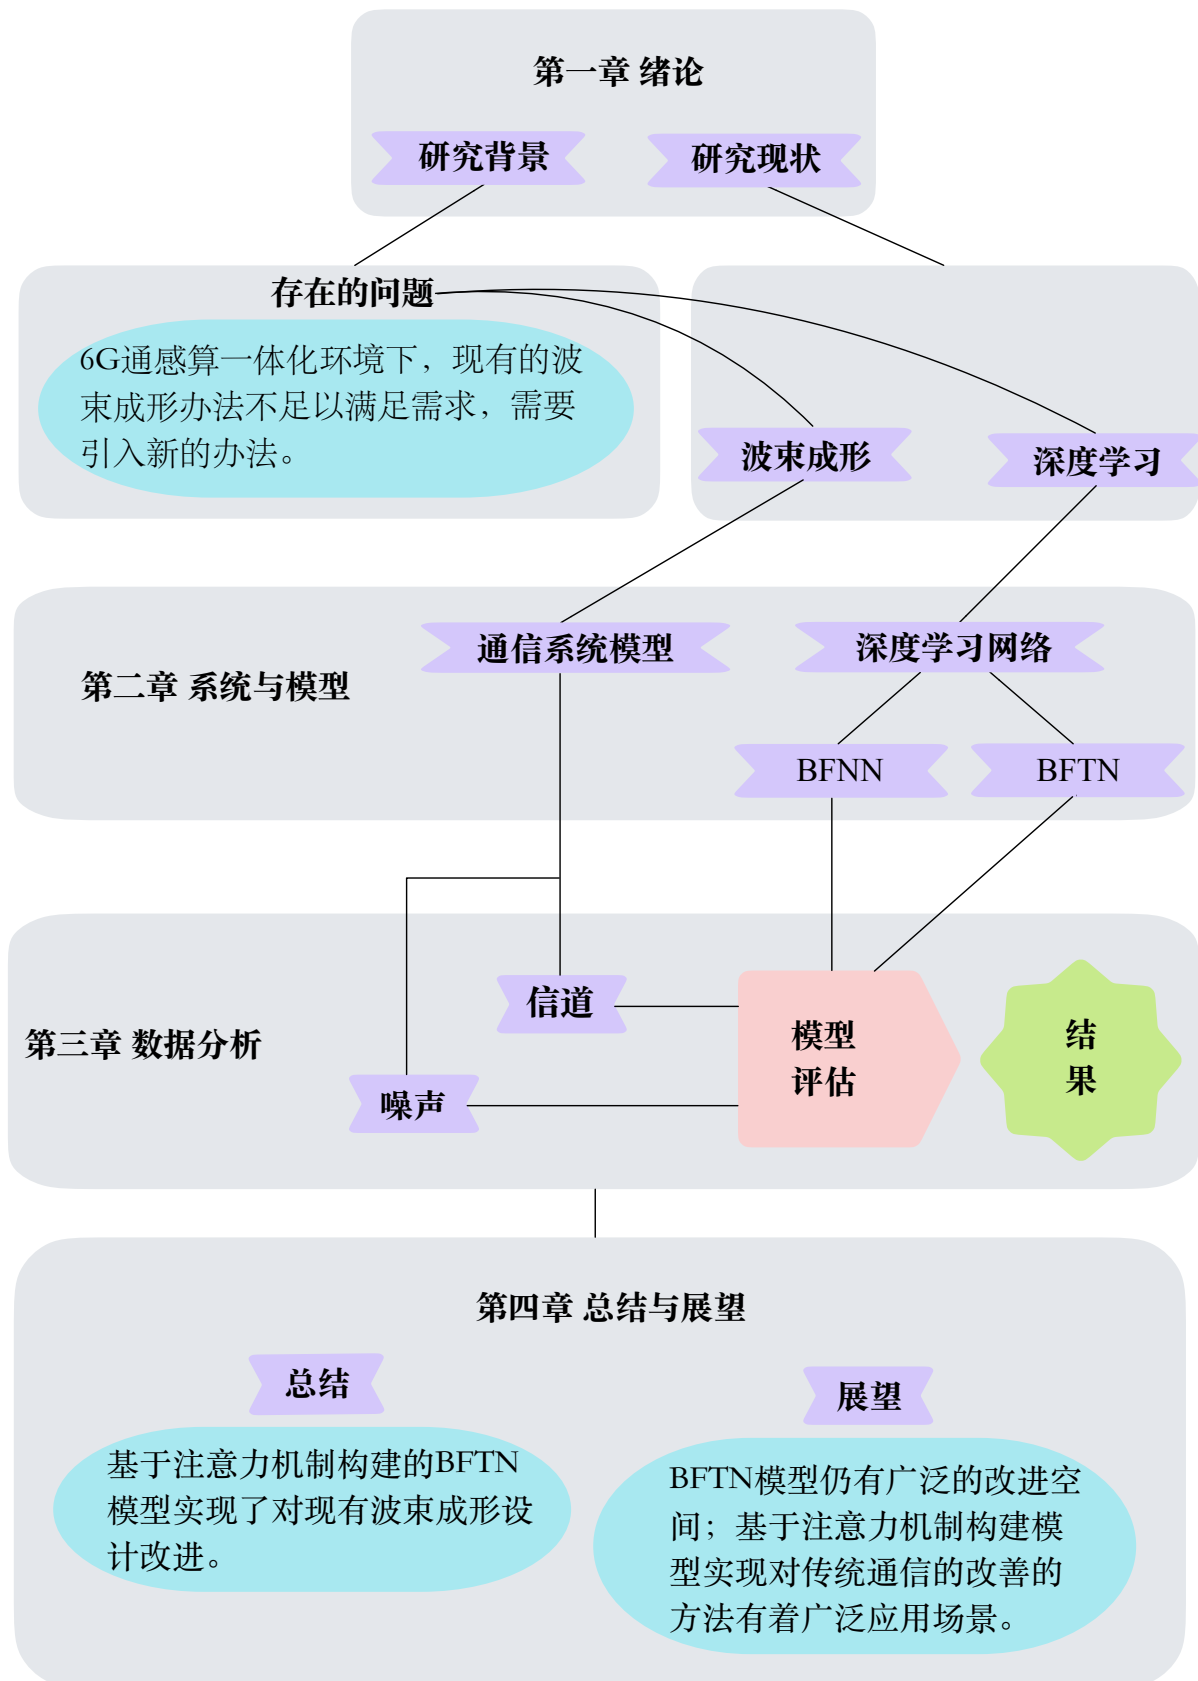


图 1.1 文章结构

第二章 系统与模型

基于第一章中的背景以及当下波束成形与深度学习的发展现状，在本章中将主要分为两个部分来构建系统与模型。第一个部分是构建波束成形所在的通信环境背景与相邻的通信环节。第二个部分将详细阐述实现波束成形调节的深度学习网络的内部构造以及实现过程。

2.1 通信系统模型

在整体通信系统模型构建开始之前，将对模型中使用到的波束成形的基本原理进行简单介绍。

波束成形的基本原理可以由图2.1表示。

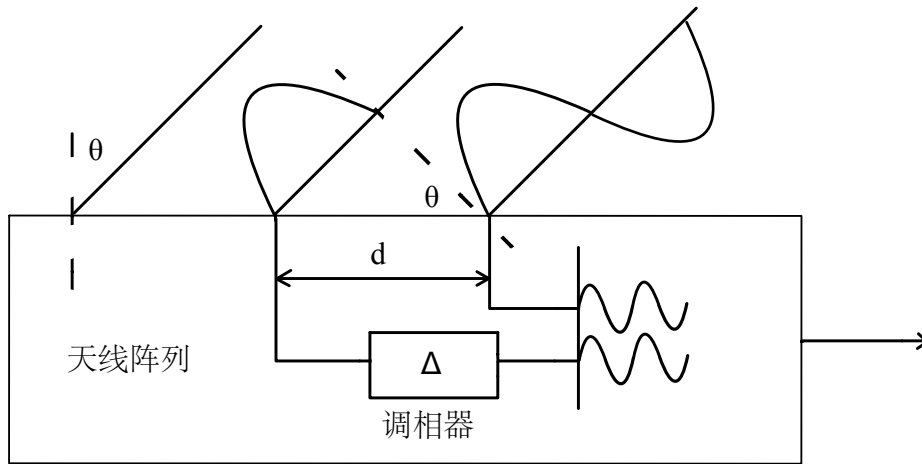


图 2.1 波束成形基本原理

在实际信号接收的应用场景中，信源位置往往远大于天线间间距，因此即便信源均匀向外辐射信号，对于天线阵列处而言，可将信号视为从无穷远处平行到达。在二维平面中，假定信道到达天线阵列处与接收面的法线呈 θ 角度。在非垂直入射的角度下，假设信源发出的是直射相干信号，因信号到达天线阵列处的路程不一，所以被天线接收时的相位也不同。在图2.1中，假设信号的载波频率为 f_c ，空间中波长与频率存在公式2.1所示的关系。

$$\lambda_c = \frac{f_c}{c} \quad (2.1)$$

在图2.1展示的环境中，设定相邻的两个天线之间接收到的信号相位差 $\Delta\phi = \pi$ 。而在波束成形中针对指定载波频率 f_c 的信号控制天线间的间距满足公式2.2表达的关系。

$$d \sin(\theta) = \frac{\Delta\phi}{2\pi} \lambda_c \quad (2.2)$$

此时，相邻的两束到达天线阵列的信号呈现大小相等，相位相反的情况。如果将两束信号直接进行叠加，信号会相互抵消抑制。但如果将其中一束信号送入调相器，进行相位 $\Delta\phi = \pi$ 的调节再叠加，就能实现信号的增益放大。

在实时通信的过程中，短时间内载波频率固定，天线间的距离保持不变，根据公式2.2，信号达到天线阵列时的所需要调节的相位 $\Delta\phi$ 仅与信号相对天线的角度位置 θ 相关。

此时，假定同时存在一个干扰源同样发射指定载波频率 f_c 的干扰信号，干扰信号垂直到达天线阵列中，如图2.2所示。因此时正在接收信源的信息，调相器阵列的参数由信源决定。因此从干扰源发射的信号也会受到相应的相移。在垂直入射的假设下，所有信号会同时到达信号的接收面，但是在经过调相器 $\Delta\phi = \pi$ 的调节后，相邻两个天线信号在接收后恰好呈现相位相反，叠加后被抵消，有效的被抑制。

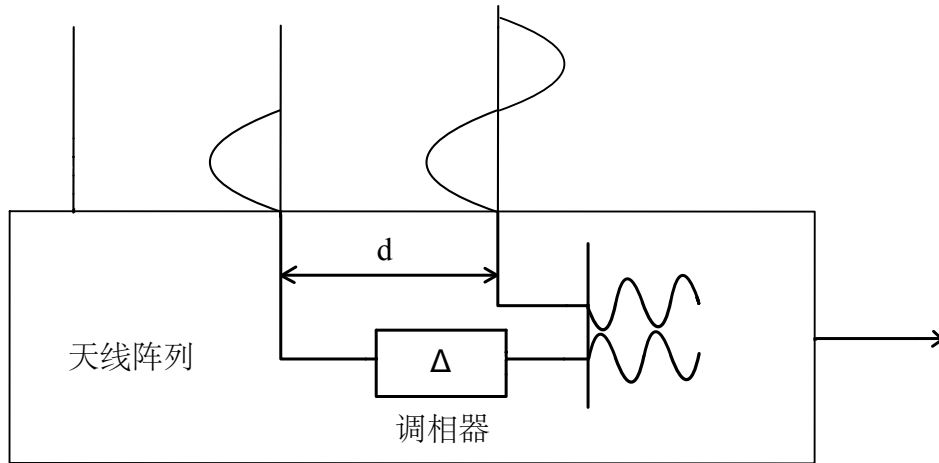


图 2.2 干扰信号对波束成形信号的影响

因此通过相位调节，波束成形在信号接收过程中实际起到了一个关于角度的滤波器的作用，对于指定方向上的有益信号进行放大，对于其他方向的信号，进行有效抑制。相似的，在发射的过程中，通过调节调相器，使得在原相干信号在经天线发射后在指定方向上进行相干叠加，从而实现了将能量向指定方向集中。

在此基础上，我们开始构建基于波束成形的通信系统模型。

MIMO 技术甚至 UM-MIMO 技术作为 6G 的核心技术，极大地提高信道容量，具有极高的频谱利用效率。通过多天线以及波束成形的方式，这个技术实现了具体场景下的高吞吐量和高频谱效率。在传统的 HBF 设计中，存在最优数字波束成形方案。本文的研究方向着重于通过调节 RF 天线阵列实现发送的频谱效率最大利用，忽略后续接收端的解码，因此可将模型简化为多发单收的模式，并且只假定每个 RF 天线与接收端之间只存在单 RF 链。于是我们便能建立图2.3所示的模型。

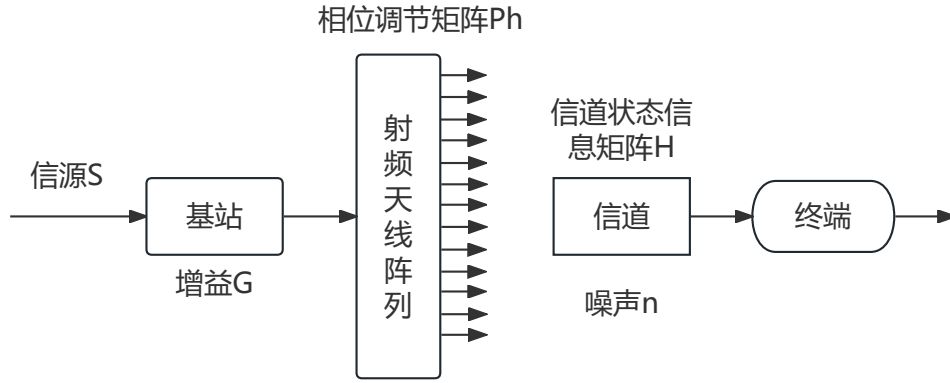


图 2.3 通信系统模型

在图2.3所示的模型中，我们假定经过编码和调制的信号源信息为 S 。 S 其中的每一个符号 s 具有单位能量，即满足公式2.3。

$$E\{|s|^2\} = 1 \quad (2.3)$$

s 经过基站进行增益放大后被传入 RF 天线阵列，其中 G 为增益系数，在此模型中 G 是一个标量，经过放大后进入 RF 天线阵列的信号表示为 $s' = Gs$ 。假设 RF 天线阵列总共地天线数量为 N_t ，而每个天线具有的延迟不同，因此形成一个大小为 $[1, N_t]$ 的相位调节矩阵 P_h 。经过相位调节的信号以 $x = GsP_h$ 的形式被送入信道。假定噪声 n 服从均值 $m = 0$ ，方差为 σ^2 的高斯分布。假定信道状态信息矩阵为 H ，则经过信道后接收端接受到的信息为 $y = GsP_hH + n$ 。

现有的波束成形设计中，频谱效率 SE 被广泛地作为衡量地指标^[40-41]。其可表示为公式2.4。

$$SE = \frac{C}{B} \quad (2.4)$$

其中 C 表示信道容量， B 表示带宽，在单位带宽下有 $SE = C$ 。当噪声为加性高斯白噪声时，香农定理指出，信道容量可以被表示为公式2.5。

$$C = B \log_2(1 + \frac{S}{N}) \quad (2.5)$$

在此模型中得到公式2.6。

$$SE = \log_2(1 + \frac{\|GsP_hH\|^2}{\sigma^2}) \quad (2.6)$$

由于 G 是标量，并且有公式2.3， SE 最大化问题被转化为求解公式2.7。

$$\max \frac{\|P_hH\|^2}{\sigma^2} \quad (2.7)$$

对于模型中相位调节矩阵 P_h ，天线对信号只进行了相移操作，对于每一天线的输入输出有 $x_i = s'_i e^{j\phi_i}$ 。模型中信道模型我们采用了 Saleh-Valenzuela 毫米波信道模型^[42-43]，模型中信道由 1 条视距路径和 $L - 1$ 条非视距路径构建，信道状态信息矩阵由公式2.8给出。

$$\mathbf{H} = \sqrt{\frac{N_t}{L}} \sum_{l=1}^L \alpha_l \mathbf{a}^h(\phi_l) \quad (2.8)$$

公式中 L 代表总路径数， α_l 表示第 l 条路径信号在基站处获得的增益， $\mathbf{a}^h(\phi_l)$ 表示在第 l 条路径，天线对信号的相移为 ϕ_l 时的响应。

2.2 深度学习网络

在这个部分，有两个模型会被介绍。一个是基于传统神经网络结构的 BFNN，它将被简介介绍，在本文后续的实验中作为对照存在。另一个是基于注意力机制构建的 BFTN，作为核心，将会被详细阐述。

在模型构建之前，首先需要明确模型的作用。在之前通信系统模型的部分中我们唯一没有详细说明的是相位调节矩阵 P_h 。深度学习网络的作用便是调整相位调节矩阵 P_h ，来获得较高的频谱效率。目前主流的调节方式有三种，一种是完全不依赖 CSI，直接进行调整的盲波束成形^[44-45]，一种是接收 CSI 反馈来波束成形^[46-47]，还有一种是基于信道估计进行波束成形^[48-49]。本文采用的是基于信道估计进行波束成形设计，选用的信道模型已于通信系统模型中进行说明。

基于信道估计进行波束成形设计会首先对信道进行估计，这一部分非本文研究方向，信道估计的结果将会以数据集的方式引入，具体数据代表的意义将在第三章中被提及。构建的深度学习网络将会以估计的 CSI 作为输入，并根据传入的 CSI 近似估计来生成由天线调节相位构成的矩阵，完成对波束成形的自适应设计。

本文中的模型都将基于目前主流使用的 Pytorch 包进行构建。建立深度学习网络的第一步便是确立网络模型应该具有的输入形式与内容，运算得到的输出形式，以及希望到达的网络对输入的作用。

因此，在深度学习网络模型设计之前，首先便是依据通信系统模型建模确定模型的输入形式与输出形式。在图2.3给出的通信系统模型中，射频天线阵列所需要接受的输入是预估的 CSI，其形式为 $[N_t, 1]$ 的复数矩阵。由于目前 Pytorch 包缺少对复数计算的支持，因此将输入形式变化为 $[2, N_t, 1]$ 的矩阵，其中 $[0, ,]$ 涵盖了原输入矩阵中的实数值， $[1, ,]$ 涵盖了原输入矩阵中的虚数值。我们将变换后的矩阵作为模型的输入。模型的输出是射频天线阵列的相位调节矩阵，对于每一个射频天线都具有到接收端的 RF 链路，每条链路的调相器独立控制，因而具有 $[N_t, 1]$ 的形状。

为了方便模型的表示，在下面两个模型中，我们设定天线数量 $N_t = 64$ 。

2.2.1 波束成形神经网络

在解决了模型输入输出问题后，需要考虑的便只剩下了明确希望到达的网络对输入的作用，而这决定了网络的结构。因此，即便在相应文章中^[50]给出了 BFNN 模型的结构，我们仍需对该模型结构进行适当解析与分析，寻找优化的方向，并在新的网络结构中对其进行改进。相较于传统计算方法，BFNN 已经具有良好的性能，这意味着通过深度学习的方式去进行波束成形设计具有重大意义。同时，在本文中为了体现提出的新模型的性能，BFNN 在第三章中也会被作为对照组设置。

在传统经典神经网络中，对于数据的操作可以分为线性部分和非线性部分。在本文讨论的问题中，尽管输入具有超过一维的维度，但本质而言仍然是估计的 CSI 将复数的实数值和虚数值分离得到的，因而模型的输入更倾向于被看作一维序列来处理。

传统经典神经网络对于一维数据，线性部分的操作将会由全连接层（由 Linear 构建）来提供，并且通过全连接层的级联，可以形成一个类似于隐藏层的结构。对于每一个全连接层，执行的操作效果可以由公式2.9表示。

$$y = xA^T + b \quad (2.9)$$

在公式2.9中 y 表示经过全连接层后的数据， y 表示进入全连接层后的数据， A^T 是权重参数的转置， b 矩阵乘法后为了方便后续处理给予的偏置。不难看出，全连接层并没有改变数据的向量空间，仍然只是原有数据的组合运算，仅仅会对特定存在意义的组合提供了便利，只对数据进行了线性处理。

为了能对数据进行更细致的处理，激活层便被作用于传统经典神经网络的非线性部分。常用于激活层的激活函数有 softmax^[51]、ReLU^[52]等。在本文中使用 ReLU 函数作为默认的激活函数。对于 ReLU 激活函数而言，他的输入输出满足公式2.10。

$$f(x) = \max(0, x) \quad (2.10)$$

公式2.10中 $f(x)$ 代表了经过激活后的数据， x 表示了激活层的输入。通过激活层，部分数据被置零，输入和输出不再具有可互易的一一对应关系，使得函数引入了非线性的部分，同时在全连接层中添加的偏置使得在激活中能够灵活的调节置零部分，从而实现可调节的非线性操作的引入。

基于传统经典神经网络处理一维数据的思路，我们初步定义了 BFNN 中的属性。除去激活层外，BFNN 具有的属性如表2.1所示。

表 2.1 BFNN 属性

层名称	构建实例
batch_norm1	BatchNorm1d(128, eps=1e-05, momentum=0.1, affine=True, track_running_stats=True)
batch_norm2	BatchNorm1d(128, eps=1e-05, momentum=0.1, affine=True, track_running_stats=True)
batch_norm3	BatchNorm1d(256, eps=1e-05, momentum=0.1, affine=True, track_running_stats=True)
dense1	Linear(in_features=128, out_features=256, bias=True)
dense2	Linear(in_features=256, out_features=128, bias=True)
dense3	Linear(in_features=128, out_features=64, bias=True)
flatten	Flatten(start_dim=1, end_dim=-1)

在表2.1给出的属性中,除了全连接层还存在着 Flatten 和 BatchNorm1d。其中 Flatten 仅仅将多个一维数据直接拼接成一个。而 BatchNorm1d^[53]是一个正则化层，主要目的是归一化数据。

利用所定义的属性，构建了如图2.4所示的波束成形矩阵调节网络模型。先对数据进行展平与拼接，并将拼接后的数据标准与正则化，随后进行特征与维度变换、激活、正则化，用更多的参数量来表示数据从而试图提取内部的关系。未避免过多的丢弃数据并使得数据处理更加进行，使用逐渐降低参数的方式，通过特征与维度变换、激活先减少一次参数数量，再特征与维度变换的方式再减少一次参数数量，使得最终模型输出的数据结果能符合前文为输出定义的形式。

在 BFNN 模型中，通过 BatchNorm1d 实现了对数据标准化、保持了梯度稳定性、增加了收敛速递、起到了正则化的效果；通过 Linear 实现了特征维度变换、特征提取和组合、数据参数学习。

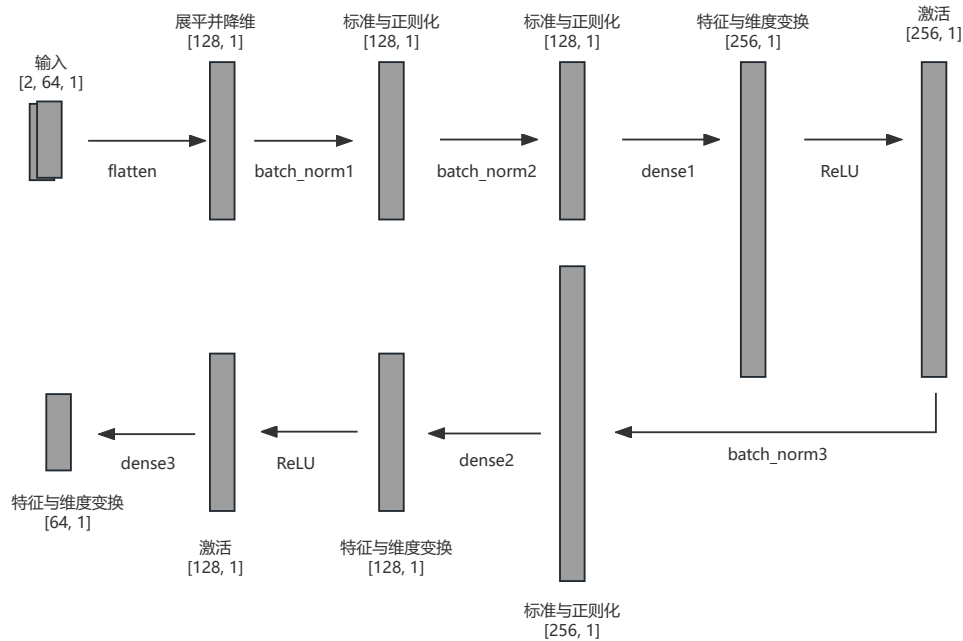


图 2.4 BFNN 模型

从模型的构建上看，BFNN 主要基于全连接等线性变化，仅仅通过激活和正则化层引入微小非线性特征，对于 CSI 的高阶特征提取效果较弱，这也容易导致对不同环境的迁移适应能力较弱。

2.2.2 波束成形 Transformer 网络

在对模型结构进行阐述之前，需要先引入一些先导概念。

为解决传统的深度学习网络中，随着网络深度增加，参数急剧膨胀导致的模型处理信息的效率快速下降以及训练时间爆炸性增加的问题，注意力机制被引入。注意力机制可

以通过训练来分配更多的资源对输入的有价值部分进行计算，同时减少或者忽略对其他部分的关注，从而在相同的参数大小下获得更好的效率。给定一个输入 $Source$ ，在注意力机制中，我们将输入看作信息的集合并将 $Source$ 转换为 $\langle Key, Value \rangle$ 的序列对。其中 Key 表示了输入信息的子信息序列， $Value$ 表示该子信息序列的重要性权重。如果我们假设我们要生成的预测输出目标为 $Query$ ，那么注意力机制将由公式2.11表示。

$$\text{Attention}(Query, Source, Value) = \sum_{i=1}^{L_x} \text{Similarity}(Query, Key(i)) * Value(i) \quad (2.11)$$

其中 $\text{Attention}(Query, Source, Value)$ 表示根据预测目标、输入信息以及子信息序列重要性权重获得的注意力， L_x 表示输入信息被分成的 $\langle Key, Value \rangle$ 的序列对的对数， $\text{Similarity}(Query, Key(i))$ 表示预测目标与当前子信息序列的相关联程度。

表 2.2 注意力模块属性

层名称	构建实例
out_proj	NonDynamicallyQuantizableLinear(in_features=64, out_features=64, bias=True)

表 2.3 TransformerEncoderLayer 模块属性

层名称	构建实例
dropout	Dropout(p=0.1, inplace=False)
dropout1	Dropout(p=0.1, inplace=False)
dropout2	Dropout(p=0.1, inplace=False)
linear1	Linear(in_features=64, out_features=2048, bias=True)
linear2	Linear(in_features=2048, out_features=64, bias=True)
norm1	LayerNorm((64,), eps=1e-05, elementwise_affine=True)
norm2	LayerNorm((64,), eps=1e-05, elementwise_affine=True)
self_attn	MultiheadAttention

在训练过程中，通过不断判断子信息序列与输出结果的关联性，动态调整权重占比与感受野，使得模型能够更加关注于起到更多作用的部分，对输入的高阶特征具有更好的提取效果。因此，为了能更好的对 CSI 进行理解，使得设计的深度学习网络能生成

更好的波束成形调节矩阵，我们构建了基于注意力机制的注意力模块，其属性由表2.2给出。

在得到可用于提取注意力的模块后，仍有一些问题等待解决。尽管注意力模块可以较好的提取输入的高阶特征，但是仅有单个注意力模块显然会造成作用小训练慢的问题，因此势必需要对注意力模块的复用。但直接级联注意力模块实际上的效果与单个注意力模块效果等同，因此需要将注意力模块与其他一些层进行封装后再级联。于是我将注意力模块与全链接层用来构建 TransformerEncoderLayer 注意力层，其中全连接层使得原有数据向更高维度变换后再引入 Dropout 来减少模型对训练数据的过拟合，解决模型迁移能力差的问题。最后再变换回输入注意力层的维度以便进行级联。TransformerEncoderLayer 的模块属性如表2.3所示，激活函数使用 ReLU 函数。

基于假定的 TransformerEncoderLayer 的模块属性以及设计的目的，我们可以构建如图2.5所示的 TransformerEncoderLayer 模块。

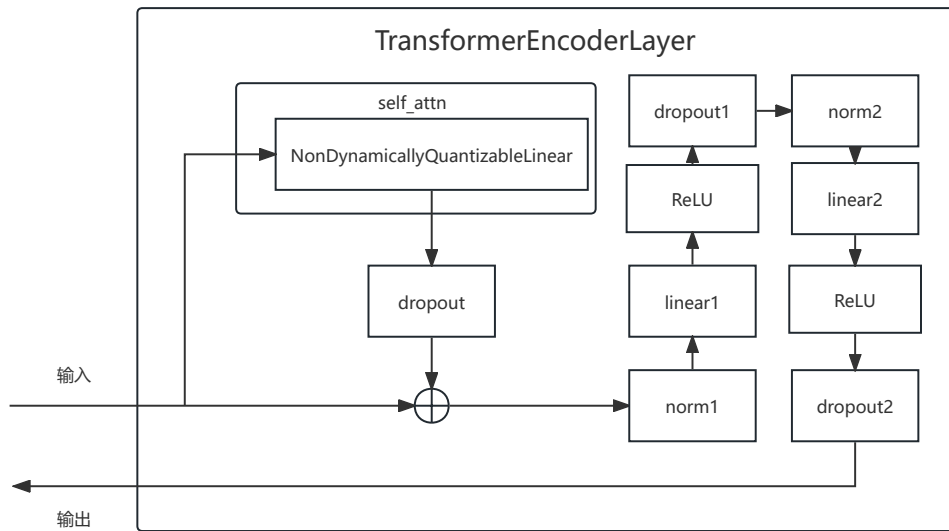


图 2.5 TransformerEncoderLayer 模块

在获得可供级联的 TransformerEncoderLayer 模块后，便可以开始构建主要的基于注意力机制的深度学习网络。本质上而言，网络通过估计的信道状态信息来生成天线的相位调节矩阵可以看成一种编码方式，通过自动学习的编码方式，实现从信道状态信息到天线的相位调节矩阵的映射。因此基于 TransformerEncoderLayer 模块和 BERT 的思想，构建一个核心模块 TransformerEncoder。

在整个模型中，TransformerEncoder 将会承担所有的高阶特征提取任务，使得网络中的其他部分可以简单通过展平和全连接就能将编码器的结果转换为可以直接使用的

表 2.4 TransformerEncoder 模块属性

层名称	构建实例
layers	ModuleList(Numbers×TransformerEncoderLayer)
norm	BatchNorm1d(2, eps=1e-05, momentum=0.1, affine=True, track_running_stats=True)

相位调节矩阵。而基于注意力构建的神经网络 BFTN 与 BFNN 的主要区别便是格外增加了这个编码器，为了结构清晰，便将其单独封装。表2.4定义了 TransformerEncoder 模块的属性。

在本文中，我们设定编码器共含有 6 层，即表2.4中 $Numbers = 6$ ，搭建如图2.6所示的 TransformerEncoder 模块。

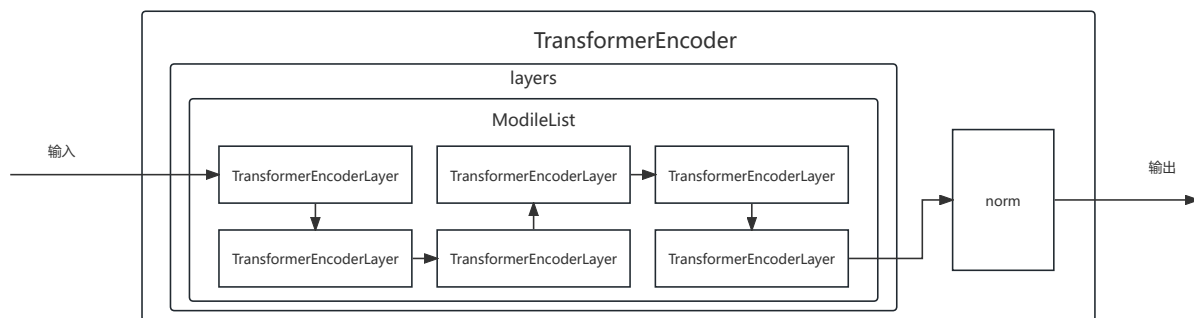


图 2.6 TransformerEncoder 模块

基于上面的基础，我们可以定义模型 BFTN。同样的，在表2.5中，我们列出了 BFTN 模型具有的属性。

表 2.5 BFTN 结构属性

层名称	构建实例
dropout_layer	Dropout(p=0.1, inplace=False)
encoder_layer	TransformerEncoderLayer
flatten_layer	Flatten(start_dim=1, end_dim=-1)
linear_layer	Linear(in_features=128, out_features=64, bias=True)
normalization_layer	BatchNorm1d(2, eps=1e-05, momentum=0.1, affine=True, track_running_stats=True)
transformer_encoder	TransformerEncoder

为了更加凸显基于注意力机制构建的 BFTN 网络模型的优越性，我们在预估信道状态信息的输入后，直接添加 Dropout 层，这意味着在不精确的信道状态信息基础上仍仅

仅取 $(1 - p) \times 100\%$ 的信息，在模型中 $p = 0.1$ 。在第三章中将会具体阐述这对于性能的影响与意义。信息在经过 Dropout 后被直接送入上文所构建的 TransformerEncoder 模块进行高阶特征的提取以及附加，之后便展平降维经全连接层输出最终的相位调节矩阵。整个过程由图2.7表示，TransformerEncoder 模块已经由上面定义，故不重复给出具体结构。

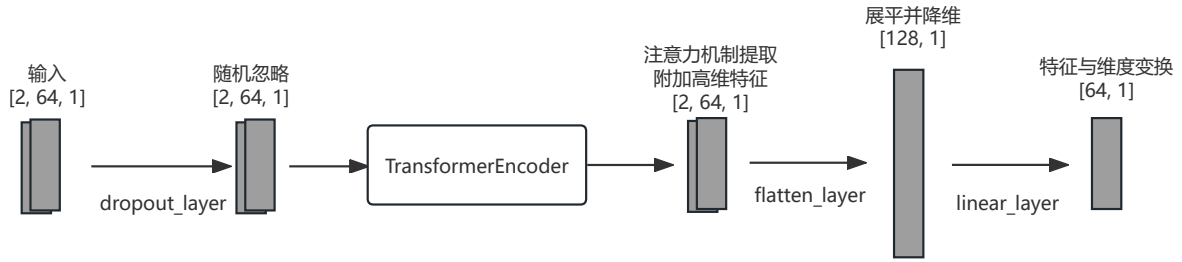


图 2.7 BFTN 模型

相较于 BFNN 模型，BFTN 中重点引入 TransformerEncoder 模块，通过这个模块，如果输入的数据中确实存在较大比例的非线性特征，这些信息将会被提取并转化为可以被线性全连接层读取的形式附加到输入信息上，从而获得模型优化的可能。实际上这是显而易见的，在天线阵列中，设定每个天线发送同频信号的情况下，每一个天线发送的信号都会对其他天线与接收端之间的信道产生影响，而在传统信号分析中，信号往往可以傅里叶展开，存在多个高频分量，也就存在着高阶特征。但这仍需要在第三章中通过数据分析进行证实。

对于在 TransformerEncoder 模块前的 Dropout 层，在实际应用中可以被直接去掉用于改善性能。它被放置在 BFTN 中的目的是为了限制 BFTN 的测试性能。经过验证的优秀的新结构往往会取得比老结构的取得更大的优势，直接进行比较对于性能的提升虽然直观，但是并不能很好的使读者意识到优越性。如果通过设置条件进行限制，在格外受限的情况下 BFTN 仍旧能取得较大的领先优势，那么将更彰显 BFTN 对于性能的改善。

在得到附加注意力的信息后，在 BFTN 中仅通过展平降维加一层全连接层便直接得到了最终的输出，避免重复提取已经被 TransformerEncoder 获得的信息，减少无效计算的同时也降低参数量，避免整体模型耗费大量运算资源。

第三章 数据分析

在本章中，第一个部分将会对仿真运行的环境以及相应的依赖进行说明，对使用的数据集以及数据形式进行阐释。同时在这一部分中还会依据上一章中通信系统建模中所给的环境，定义一个衡量模型性能的指标。本章的第二部分将会依据定义的指标，从环境噪声相对值和通信信道建模两个方面对于模型的抗干扰性以及鲁棒性进行分析并给出初步的结论。

3.1 仿真

仿真所依赖的环境版本以及主要依赖的包如表3.1所示。

表 3.1 环境以及主要依赖版本

环境/依赖	Python	PyTorch	CUDA
版本	3.9.16	2.0.0	11.7

依据上一章中信道模型的定义以及相应学者所做的工作^[54]，我们生成了相应的数据集，环境对应的参数在表3.2中进行详细展示。表中未特别注明是测试环境的代表既可以是训练环境也可以是测试环境，特别注明的只作为测试环境。

表 3.2 环境及其环境信噪比以及信道路径信息

环境名称	信噪比 SNR (dB)	路径数 L
环境 A	-20	3
环境 B	0	3
环境 C	20	3
环境 D（测试）	20	2
环境 E（测试）	20	3
环境 F（测试）	20	4

如表3.2所示，数据集的数据主要分为两个部分的数据，一个部分是路径数 $L = 3$ 的

时候，信噪比 $SNR = -20dB$ ， $SNR = 0dB$ ， $SNR = 20dB$ 时生成的信道模型数据。另一个部分是当信噪比保持在 $SNR = 20dB$ ，路径数 $L = 2$ ， $L = 3$ ， $L = 4$ 时产生的信道模型数据。前者是为了衡量不同信噪比情况下训练的模型在不同信噪比情况下的表现，后者是为了衡量不同信道环境对于模型输出的预测准确度影响。

对于每一个路径数 L 和信噪比 SNR 确定的环境中的数据，都会有训练和验证两个部分组成。训练集包含 10^5 个样本，验证集包含 10^4 个样本。每个样本包含基于指定路径数量 L 进行的信道估计数据 H_{est} 以及 L 趋近无穷的实际完美信道数据 H 。在实际过程中我们可以获得的是 H_{est} ，我们将估计得到的 H_{est} 送入模型。模型会根据输入的估计的 H_{est} 计算得到一个相位调节矩阵 P_h 。

但并非任意的相位调节矩阵 P_h 都能使得频谱效率达到最大值。相较于传统的深度学习方法中输出的结果会有标签进行参照，从而以均方差等指标作为模型的损失进行优化，波束成形并没有一个绝对完美的相位调节矩阵作为对比。因此，如何设计模型的损失函数，定义模型的优化方案成为了问题的关键。

公式2.6指出了频谱效率的计算方式。对于通信系统模型而言，我们想要通过调节相位调节矩阵 P_h ，使得频谱效率 SE 达到最大值，但在深度学习中，模型是向着损失函数减小的方向进行优化。因此如果我们将 -SE 作为深度学习网络的损失函数，通过训练，就能同时满足损失函数的最小化和频谱效率 SE 的最大化。对于多次训练取均值，于是损失函数的定义由公式3.1给出。

$$\text{Loss} = -\text{SE} = -\frac{1}{N} \sum_{n=1}^N \log_2 \left(1 + \frac{\|G_s P_h H\|^2}{\sigma^2} \right) \quad (3.1)$$

同时因为损失函数直接被定义为频谱效率的相反值，在最终测量频谱效率时可直接通过对损失函数取相反值得到，减少相应计算。

模型的优化轮次被设定为 2000 轮，将总体学习率设置为 $1e-3$ 。为了在训练中能有较快的收敛速度和更好的参数调整能力，并避免在极值附近梯度消失和梯度爆炸问题的出现，Adam 优化器^[55]被引入。为了减少在多轮训练之后的无效震荡，在本文中为学习率设置了调度（scheduler）和里程碑（milestone）来优化深度学习模型的训练过程。通过合理的学习率调整策略和里程碑选择，提高模型的收敛速度、稳定性和泛化能力，从而在训练过程中获得更好的性能和结果。为了加快模型的训练和验证速度，批处理量被设置为 64。

3.2 结果分析

毋庸置疑的是，环境的噪声干扰对于实际通信过程中的频谱效率有着较大的影响。在衡量模型的性能中，本文使用了信噪比来作为噪声相对信号的影响的自变量。我们将分别在信噪比为 -20dB ， 0dB ， 20dB 环境中训练好的模型置于信噪比可变的环境中进行频谱效率的测量，其中不同训练环境信噪比下 BFNN 模型频谱效率与环境信噪比的关系如图3.1a所示，不同训练环境信噪比下 BFTN 模型频谱效率与环境信噪比的关系如图3.1b所示。




图 3.1 不同信噪比环境下训练的模型频谱效率与信噪比的关系曲线

为了方便模型结果的呈现，在表3.2的基础上格外增加了训练环境名称与训练得到模型后缀名称的对应关系形成表3.3。

表 3.3 模型后缀命名与环境的关系

环境名称	信噪比 SNR (dB)	路径数 L	模型后缀名称
环境 A	-20	3	n20db
环境 B	0	3	p0db
环境 C	20	3	p20db
环境 D (测试)	20	2	Lest1
环境 E (测试)	20	3	Lest3
环境 F (测试)	20	4	Lest2

在图例中，模型会以模型名称加模型后缀名称的方式来被表示。以图3.1为例，在图3.1的两个子图的图例中， $n20db$ 表示在 $-20dB$ 环境下训练得到的模型， $p0db$ 表示在 dB 环境下训练得到的模型， $p20db$ 表示在 $20dB$ 环境下训练得到的模型。

从图3.1a所给出的不同训练环境信噪比下 BFNN 的频谱效率与环境信噪比关系曲线中我们可以发现，在信噪比较高的环境下训练得到的模型在不同信噪比环境下均比低信噪比环境下训练得到的模型能够产生更好的频谱效率。在信噪比较低时，由于环境噪声占据了主要，信号即便通过不同性能的波束成形模型进行调制，但相对于噪声所具有的巨大能量，整体频谱效率的差距不明显。在实际较高信噪比条件下，由于有效信号占据主导地位，在经过了不同信噪比训练后的模型后，模型的性能差距能够较好的展现在频谱效率的差距中，因此频谱效率的差距较为明显。

对于图3.1b所给出的不同训练环境信噪比下 BFTN 的频谱效率与环境信噪比关系曲线，在 $0db$ 环境下训练的模型也同样获得了比在 $-20db$ 环境下训练的模型更好的训练结果。但是对于在 $20db$ 环境下训练的模型，结果却并未好于在 $0db$ 环境下训练的模型。通过小范围的尝试与调整，发现这个现象是由于训练不充分引起的。随着训练轮次的增加与多次训练后学习率的逐渐细化， $20db$ 环境下训练的模型逐渐超越在 $0db$ 环境下训练的模型。受到相应训练时间与设备的限制，对于优化轮次为 2000 轮，学习率为 $1e-3$ 的总体训练环境而言，在 $20db$ 环境下训练的模型并未得到充分训练故表现不佳，在完全训练情况下仍然符合上述从 BFNN 模型中得到的结论。在较低的信噪比环境下，BFTN 模型和 BFNN 模型一样，由于噪声占据主导地位，不同信噪比环境下训练得到的模型产生的频谱效率差距较小。比较不同信噪比训练后的模型在实际较高信噪比条件下频谱效率的差距，BFTN 模型经过不同信噪比环境训练后的差距相对较小，相对这意味着通过注意力机制，即便训练环境的信噪比较小，构造的模型仍旧能获得一些信噪比较大环境下才能获得的特征。在训练过程中，即便存在巨大的干扰，模型也能对受到复杂干扰的占极小部分的有效信息进行抓取学习，从而获得高效的增益。

基于上述得到的结果，不难得出一个初步的结论，即在保证模型经过充分训练的前提下，在可能的情况下通过提高训练环境下的信噪比，抑制训练环境的噪声，使模型获得训练数据中的有效信号部分占尽可能高的比重，可以使得模型在实际环境任意信噪比情况下获得更优秀的性能。

为了直观展示 BFTN 模型相较于 BFNN 模型的改进，为了控制变量，我们选取了训练较为充分的在 $0db$ 环境下训练的两个模型而非 $20db$ 进行了单独对比，2 个模型的频谱效率与环境信噪比的关系曲线如图3.2所示。

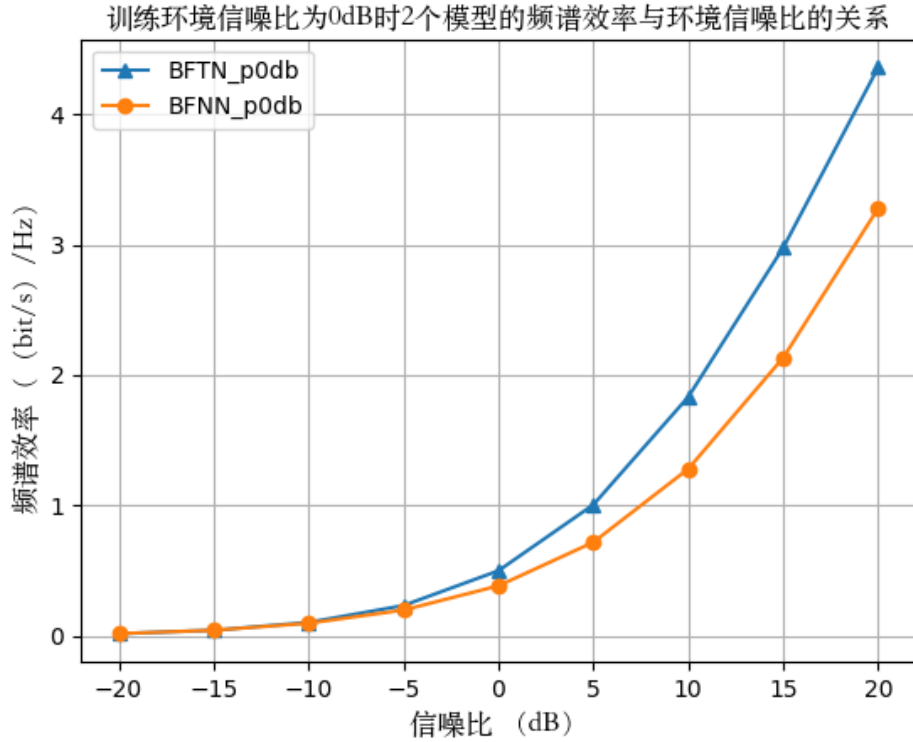


图 3.2 信噪比 SNR=0 情况下训练得到的两个模型的频谱效率对比

在信噪比较低的情况下，由于噪声占主要成分，即便信号经过了两个波束成形模型，但受限于功率，都不能获得较好的频谱效率。随着实际环境中信噪比的不断增大，从 -10dB 开始 BFTN 模型相较于 BFNN 模型的性能优越性便能图3.2上直观地被观察出。并且随着信噪比的逐渐提高，BFTN 模型相较于 BFNN 模型性能的改善程度也逐渐拉大。对于实际一般通信场景下，环境的信噪比一般在 26dB 以上。在 20dB 处，BFTN 模型的频谱效率 (4.3598 bit/s/Hz) 相较于 BFNN 模型的频谱效率 (3.2794 bit/s/Hz) 已经取得了 32.95% 的提升。伴随着实际场景信噪比的提升，BFTN 模型相较于 BFNN 模型所获得的频谱效率增益会进一步扩大。

这意味着不论从相同信噪比的训练环境下训练得到的 BFTN 模型相较于 BFNN 模型在实际中拥有更高的频谱效率的角度，还是从相同模型情况下低信噪比环境下训练得到的 BFTN 模型因为训练噪声存在而受到的性能影响小的角度，都能确定的是基于注意力机制的 BFTN 模型拥有着从复杂严重干扰下剥离仅占小部分的有效信息并提取的能力。在训练环境噪声无法被剥离抑制的情况下，使用基于注意力机制的 BFTN 模型仍能进行有效的训练。图3.1和图3.2所展示的结果有力的证明了 BFTN 模型具有极强的抗干扰能力。

除了抗干扰能力，鲁棒性也是衡量模型的另一个重要的指标。相较于抗干扰性更加关注环境噪声对模型的影响，鲁棒性更侧重于不同信道建模的方式之间的差异性对模型的影响。

在依据公式2.8进行的信道建模中，可以通过改变路径数 L 来实现不同的信道环境建模。为了对模型的鲁棒性进行测试，需要将模型在不同信道建模环境下进行运行与比较。为了节约训练的时间，本文利用了抗干扰性分析中已经在信噪比为 20dB ， $L = 3$ 信道建模情景下经过 2000 轮训练后的模型作为进一步需要测试的模型，减少了模型的重复训练。




图 3.3 BFNN 对于不同信道的鲁棒性

以图3.3展示的不同信道路径数量下 BFNN 模型的频谱效率与环境信噪比的关系为例，将经过训练的 BFNN 模型分别置于表3.3中以三种不同路径数 L 进行建模的测试环境中进行测量，通过比较不同信噪比情况下模型的频谱效率对模型的泛化能力和可迁移能力进行衡量。根据表3.3中的对应关系， $BFNN_Lest1$ 表示了 $L = 2$ 时的信道环境下进行测试取得的结果， $BFNN_Lest2$ 表示了 $L = 4$ 时的信道环境下进行测试取得的结果， $BFNN_Lest3$ 表示了 $L = 3$ 时的信道环境，即与训练环境相同时进行测试

取得的结果。

对于 $BFNN_Lest3$ 曲线而言，因为训练环境与测试环境所使用的信道模型是同一个模型，因此不存在因环境不同而产生的迁移损失，因此频谱效率始终保持着较高的水准。对于另两条 $BFNN_Lest2$ 和 $BFNN_Lest1$ 曲线，因为现实测试环境信道建模中路径数 L 与训练环境信道建模中路径数 L 不同，两个环境的信道建模存在差异，因此在训练环境中训练好的模型并不能完美的运行和适应不同的信道测试环境，从而导致实际测试环境下的频谱效率相较于训练环境和测试环境相匹配的 $BFNN_Lest3$ 曲线有所下降。

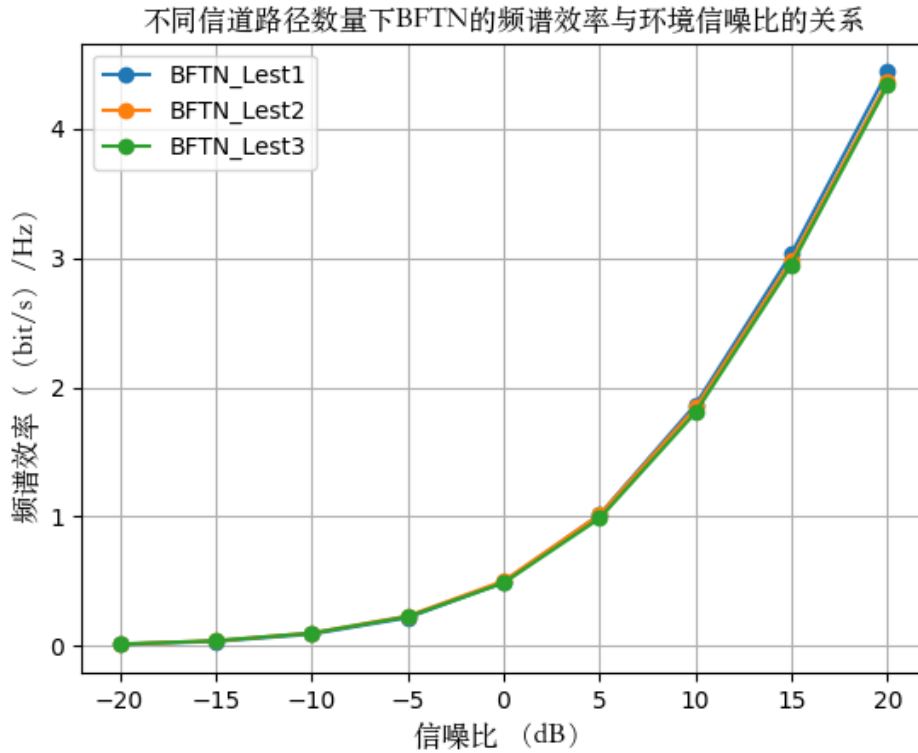


图 3.4 BFTN 对于不同信道的鲁棒性

依据与 BFNN 模型同样的方式，将经过训练的 BFTN 模型分别置于不同测试环境中进行测量，图3.4展示了不同信道路径数量下 BFTN 模型的频谱效率与环境信噪比的关系。可以很明显的看出，相较于 BFNN 模型，尽管测试环境信道建模中路径数 L 不同，信道建模存在差异，但是获得的 BFTN 模型的频谱效率与环境信噪比曲线几乎重合，BFTN 模型在与训练环境信道不同的环境中依旧能获得接近于最理想的测试训练环境相同情况下的结果。

同时，基于先前的处理，这个用于测试模型是信噪比为 $20dB$ ， $L = 3$ 信道建模情景下经过 2000 轮训练后的模型，而如同在上文分析模型抗干扰能力的部分提到的，这个训练次数对于高信噪比环境下进行训练的 BFTN 模型而言是不足以达到训练完成性能达到稳定的程度的。而图3.4的结果表明，即便模型处于未完全训练的状态，但也已经体现出了相当强大的鲁棒性。单独为此模型继续增加训练轮次并适 BFTN 当调整学习率后，新得到的模型在不同测试环境中频谱效率曲线之间的差距进一步缩小，这表明了 BFTN 模型对于不同信道建模环境具有极强的鲁棒性。

更为关键的一点是，如图2.7所示的 BFTN 模型，数据在进入真正起作用的模型前，首先经历了一层人为引入的随机忽略层。对于实际起作用的模型而言，真正的输入是经过随机忽略后的估计的信道状态信息。

对于这个随机忽略层，它通过对输入数据的每一部分以一定的概率进行置零，这使得输入的信息没有可能通过随机的方式恰好抵消实际信道状态信息与估计状态信息之间的差距，没有任何获得因随机而产生增益的可能，对于输入数据所包含的信息量一定起到削减的作用。

本身信道状态信息已经不是完美的真实状态信息，而是基于一定方法得到的有损信息，这部分差异是需要模型本身的鲁棒性去克服的。但是由于随机置零使得模型获得的输入信息会比本应输入的估计的信道状态信息更少，BFTN 模型在进行评估的时候面临着格外的限制和挑战。从这个角度上看，这意味着在上述的评估中，BFTN 模型凭借着更有限更被干扰的残缺信息输入获得了比接收完整信息输入的 BFNN 模型更好的结果，表明了 BFTN 模型模型在付出部分用于克服格外因素的代价后，仍然具有远超 BFNN 模型的抗干扰能力和鲁棒性，这更加证实了 BFTN 模型具有的极强的抗干扰能力和鲁棒性。

因此，在实际模型的部署阶段，可以直接将格外附加的随机忽略层进行剥离来获得更好的性能。

第四章 总结与展望

4.1 总结

在 6G 通感算一体化背景下，人工智能技术与通信、感知、计算的结合越来越紧密，在波束成形领域，已经取得了一定进展与成果。

本文提出的基于注意力机制的 BFTN 模型，在以下几个方面对现有的深度学习波束成形网路进行了改进：

- 引入自注意力和多头注意力机制，使得目标网络模型能够在处理输入的估计的信道状态信息时，将注意力集中在不同区域的信息上并捕捉提取之间的依赖关系，同时也通过更多的注意力头进行权重的计算，能关注到更多输入中包含的高阶信息特征，增强了模型对输入的表达能力。
- 在整体模型的构建中，更广泛地使用了残差链接和正则化，在减少了因梯度消失和梯度爆炸导致的模型负优化的同时，保留了更多输入的估计的信道状态，减少信息丢失，稳定模型的训练过程，提高模型的泛化能力，并增强模型对输入数据的抗干扰性和鲁棒性。

在经过上述方式改进后，BFTN 模型可以自适应地对输入信号进行注意力加权，根据信号的重要性调整波束权重，实现更灵活的感受野大小的调节与特征提取。与传统的 BFNN 模型相比，BFTN 模型更加灵活和准确地捕捉到输入信号的相关性，从而实现更好的波束成形效果。

在对构建的 BFTN 模型的抗干扰性和鲁棒性的测试中，相较于 BFNN 模型，BFTN 模型能在同等噪声环境下，表现出获得了更优的频谱效率，并且甚至在预估 CSI 被严重干扰情况下，也能有良好的表现，具有良好的迁移性和适应性，具备了强大的抗干扰性和鲁棒性。

4.2 展望

在 6G 通感算一体化背景下，6G 通信技术的不断发展，对高速、低延迟通信的需求将进一步增加。波束成形作为实现高效通信的关键技术，是 6G 网络中不可或缺的一

部分，基于注意力机制的 BFTN 模型在波束成形设计领域将持续发挥重要作用，尽管 BFTN 模型在频谱效率上已经取得了较好的效果，但仍然在多个不同方向上具有极其广阔的改进空间。

对于 BFTN 模型本身而言，在设计构建的时候，仅仅只是在目前多数深度学习研究者常用的参数中随机选取，对于对编码器模块的注意力层数和参数而言，在很大可能性上，并不一定是最适合波束成形设计的。通过调整编码器模块中的注意力层的内部结构和整编码器模块含有的注意力层层数，对经过编码器之后的网络结构调整，附加更多的编码器等方式，都会使得 BFTN 模型的性能受到影响，基于注意力机制实现的 BFTN 网络本身仍存在一定的改进空间。

随着人工智能和深度学习技术的不断进步，更新更优秀的架构与思想可以被更多应用于波束成形网络的改进。即便在目前而言，仍及存在着众多基于 Transformer 的改进型模型，通过借鉴改进思路，BFTN 模型也存在着改进可能。同时，一些全新的架构，就如在绪论中提到的基于状态空间的 mamba 模型，也存在着可以通过使用类似的机制与思路实现改进波束成形网络的可能。

此外，通过注意力等新机制构建网络模型工具改进波束成形网络这一种使用人工智能技术赋能传统通信领域的方法可以被广泛地用于和其他 6G 关键技术相结合。例如，使用人工智能赋能通信的方式，我在对终端向基站发送的 CSI 反馈信息进行压缩以及重建的方向上同样取得了一些进展^[56]。

毋庸置疑，人工智能赋能通信领域这一方法能帮助构建更加智能和高效的通信系统，实现全面感知的通信网络，为各种应用场景提供更全面、稳定和高质量的通信服务，具有广阔的发展前景。

参考文献

- [1] LU L, LI G Y, SWINDLEHURST A L, et al. An overview of massive MIMO: Benefits and challenges[J]. IEEE journal of selected topics in signal processing, 2014, 8(5): 742-758.
- [2] ROH W, SEOL J Y, PARK J, et al. Millimeter-wave beamforming as an enabling technology for 5G cellular communications: Theoretical feasibility and prototype results[J]. IEEE communications magazine, 2014, 52(2): 106-113.
- [3] KAMEL M, HAMOUDA W, YOUSSEF A. Ultra-dense networks: A survey[J]. IEEE Communications surveys & tutorials, 2016, 18(4): 2522-2545.
- [4] MAO Y, YOU C, ZHANG J, et al. A survey on mobile edge computing: The communication perspective[J]. IEEE communications surveys & tutorials, 2017, 19(4): 2322-2358.
- [5] FOUKAS X, PATOUNAS G, ELMOKASHFI A, et al. Network slicing in 5G: Survey and challenges[J]. IEEE communications magazine, 2017, 55(5): 94-100.
- [6] CHEN Z, MA X, ZHANG B, et al. A survey on terahertz communications[J]. China Communications, 2019, 16(2): 1-35.
- [7] JI H, PARK S, YEO J, et al. Ultra-reliable and low-latency communications in 5G downlink: Physical layer aspects[J]. IEEE Wireless Communications, 2018, 25(3): 124-130.
- [8] SIDDIQUI M U A, ABUMARSHOUD H, BARIAH L, et al. URLLC in Beyond 5G and 6G Networks: An Interference Management Perspective[J]. IEEE Access, 2023, 11: 54639-54663.
- [9] SHE C, DONG R, GU Z, et al. Deep learning for ultra-reliable and low-latency communications in 6G networks[J]. IEEE network, 2020, 34(5): 219-225.
- [10] WANG C X, YOU X, GAO X, et al. On the Road to 6G: Visions, Requirements, Key Technologies, and Testbeds[J]. IEEE Communications Surveys & Tutorials, 2023, 25(2): 905-974.
- [11] VOROBYOV S A, GERSHMAN A B, LUO Z Q. Robust adaptive beamforming using worst-case performance optimization: A solution to the signal mismatch problem[J]. IEEE transactions on signal processing, 2003, 51(2): 313-324.
- [12] NGUYEN N T, MA M, LAVI O, et al. Deep Unfolding Hybrid Beamforming Designs for THz Massive MIMO Systems[J]. IEEE Transactions on Signal Processing, 2023, 71: 3788-3804.
- [13] MOLISCH A F, RATNAM V V, HAN S, et al. Hybrid beamforming for massive MIMO: A survey[J]. IEEE Communications magazine, 2017, 55(9): 134-141.
- [14] GREENBERG J E, ZUREK P M. Evaluation of an adaptive beamforming method for hearing aids[J]. The Journal of the Acoustical Society of America, 1992, 91(3): 1662-1676.
- [15] YANG T. Deconvolved conventional beamforming for a horizontal line array[J]. IEEE Journal of Oceanic Engineering, 2017, 43(1): 160-172.
- [16] HOSOYA K, PRASAD N, RAMACHANDRAN K, et al. Multiple sector ID capture (MIDC): A novel beamforming technique for 60-GHz band multi-Gbps WLAN/PAN systems[J]. IEEE Transactions on Antennas and Propagation, 2014, 63(1): 81-96.
- [17] RAZAVIZADEH S M, AHN M, LEE I. Three-dimensional beamforming: A new enabling technology for 5G wireless networks[J]. IEEE Signal Processing Magazine, 2014, 31(6): 94-101.
- [18] COX H, ZESKIND R, OWEN M. Robust adaptive beamforming[J]. IEEE Transactions on Acoustics, Speech, and Signal Processing, 1987, 35(10): 1365-1376.

- [19] LAVDAS S, GKONIS P K, ZINONOS Z, et al. An adaptive hybrid beamforming approach for 5G-MIMO mmWave wireless cellular networks[J]. IEEE Access, 2021, 9: 127767-127778.
- [20] HUA H, XU J, HAN T X. Optimal Transmit Beamforming for Integrated Sensing and Communication[J]. IEEE Transactions on Vehicular Technology, 2023, 72(8): 10588-10603.
- [21] HUANG H, PENG Y, YANG J, et al. Fast beamforming design via deep learning[J]. IEEE Transactions on Vehicular Technology, 2019, 69(1): 1065-1069.
- [22] LUIJTEN B, COHEN R, DE BRUIJN F J, et al. Adaptive ultrasound beamforming using deep learning[J]. IEEE Transactions on Medical Imaging, 2020, 39(12): 3967-3978.
- [23] MERCHANT K, REVAY S, STANTCHEV G, et al. Deep learning for RF device fingerprinting in cognitive communication networks[J]. IEEE journal of selected topics in signal processing, 2018, 12(1): 160-167.
- [24] YE H, LI G Y, JUANG B H. Power of deep learning for channel estimation and signal detection in OFDM systems[J]. IEEE Wireless Communications Letters, 2017, 7(1): 114-117.
- [25] MCCULLOCH W S, PITTS W. A logical calculus of the ideas immanent in nervous activity [J]. The bulletin of mathematical biophysics, 1943, 5: 115-133.
- [26] MCCLELLAND J L, RUMELHART D E, GROUP P R, et al. Parallel distributed processing, volume 2: Explorations in the microstructure of cognition: Psychological and biological models: vol. 2[M]. Cambridge: MIT press, 1987.
- [27] RUMELHART D E, HINTON G E, WILLIAMS R J. Learning representations by back-propagating errors[J]. nature, 1986, 323(6088): 533-536.
- [28] KRIZHEVSKY A, SUTSKEVER I, HINTON G E. ImageNet classification with deep convolutional neural networks[J]. Communications of the ACM, 2017, 60(6): 84-90.
- [29] SIMONYAN K, ZISSERMAN A. Very deep convolutional networks for large-scale image recognition[J]. arXiv preprint arXiv:1409.1556, 2014.
- [30] HE K, ZHANG X, REN S, et al. Deep residual learning for image recognition[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. Las Vegas: IEEE, 2016: 770-778.
- [31] RUMELHART D E, HINTON G E, WILLIAMS R J. Learning representations by back-propagating errors[J]. nature, 1986, 323(6088): 533-536.
- [32] ELMAN J L. Finding structure in time[J]. Cognitive science, 1990, 14(2): 179-211.
- [33] HOCHREITER S, SCHMIDHUBER J. Long short-term memory[J]. Neural computation, 1997, 9(8): 1735-1780.
- [34] SAK H, SENIOR A W, BEAUFAYS F. Long short-term memory recurrent neural network architectures for large scale acoustic modeling[C]//INTERSPEECH. Singapore: International Speech Communication Association (ISCA), 2014: 338-342.
- [35] SUTSKEVER I, VINYALS O, LE Q V. Sequence to Sequence Learning with Neural Networks[C]//Advances in Neural Information Processing Systems: vol. 27. Montreal: Curran Associates, Inc., 2014.
- [36] BAHDANAU D, CHO K, BENGIO Y. Neural machine translation by jointly learning to align and translate[J]. arXiv preprint arXiv:1409.0473, 2014.
- [37] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is All you Need[C]//GUYON I, LUXBURG U V, BENGIO S, et al. Advances in Neural Information Processing Systems: vol. 30. Long Beach: Curran Associates, Inc., 2017.
- [38] DEVLIN J, CHANG M W, LEE K, et al. Bert: Pre-training of deep bidirectional transformers for language understanding[J]. arXiv preprint arXiv:1810.04805, 2018.

- [39] GU A, DAO T. Mamba: Linear-time sequence modeling with selective state spaces[J]. arXiv preprint arXiv:2312.00752, 2023.
- [40] YU X, SHEN J C, ZHANG J, et al. Alternating minimization algorithms for hybrid precoding in millimeter wave MIMO systems[J]. IEEE Journal of Selected Topics in Signal Processing, 2016, 10(3): 485-500.
- [41] SOHRABI F, YU W. Hybrid digital and analog beamforming design for large-scale antenna arrays[J]. IEEE Journal of Selected Topics in Signal Processing, 2016, 10(3): 501-513.
- [42] GAO X, DAI L, HAN S, et al. Reliable beamspace channel estimation for millimeter-wave massive MIMO systems with lens antenna array[J]. IEEE Transactions on Wireless Communications, 2017, 16(9): 6010-6021.
- [43] HE H, WEN C K, JIN S, et al. Deep learning-based channel estimation for beamspace mmWave massive MIMO systems[J]. IEEE Wireless Communications Letters, 2018, 7(5): 852-855.
- [44] REN S, SHEN K, ZHANG Y, et al. Configuring Intelligent Reflecting Surface With Performance Guarantees: Blind Beamforming[J]. IEEE Transactions on Wireless Communications, 2023, 22(5): 3355-3370.
- [45] LAI W, SHEN K. Blind Beamforming for Intelligent Reflecting Surface: A Reinforcement Learning Approach[C]//ICASSP 2024-2024 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). Seoul: IEEE, 2024: 8956-8960.
- [46] WEN C K, SHIH W T, JIN S. Deep learning for massive MIMO CSI feedback[J]. IEEE Wireless Communications Letters, 2018, 7(5): 748-751.
- [47] GUO J, WEN C K, JIN S, et al. Overview of deep learning-based CSI feedback in massive MIMO systems[J]. IEEE Transactions on Communications, 2022, 70(12): 8017-8045.
- [48] YANG S, LYU W, HU Z, et al. Channel Estimation for Near-Field XL-RIS-Aided mmWave Hybrid Beamforming Architectures[J]. IEEE Transactions on Vehicular Technology, 2023, 72(8): 11029-11034.
- [49] HUANG Z, ZHENG B, ZHANG R. Roadside IRS-Aided Vehicular Communication: Efficient Channel Estimation and Low-Complexity Beamforming Design[J]. IEEE Transactions on Wireless Communications, 2023, 22(9): 5976-5989.
- [50] LIN T, ZHU Y. Beamforming design for large-scale antenna arrays using deep learning[J]. IEEE Wireless Communications Letters, 2019, 9(1): 103-107.
- [51] JANG E, GU S, POOLE B. Categorical reparameterization with gumbel-softmax[J]. arXiv preprint arXiv:1611.01144, 2016.
- [52] AGARAP A F. Deep learning using rectified linear units (relu)[J]. arXiv preprint arXiv:1803.08375, 2018.
- [53] IOFFE S, SZEGEDY C. Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift[C]//BACH F, BLEI D. Proceedings of Machine Learning Research: Proceedings of the 32nd International Conference on Machine Learning: vol. 37. Lille, France: PMLR, 2015: 448-456.
- [54] ALKHATEEB A, EL AYACH O, LEUS G, et al. Channel estimation and hybrid precoding for millimeter wave cellular systems[J]. IEEE journal of selected topics in signal processing, 2014, 8(5): 831-846.
- [55] KINGMA D P, BA J. Adam: A method for stochastic optimization[J]. arXiv preprint arXiv:1412.6980, 2014.
- [56] XIA Y, QI B. CSI Reconstruction in UM-MIMO Systems Based on Improved ViT and TNT Networks[C]//2023 11th International Conference on Information Systems and Computing Technology (ISCTech). Qingdao: IEEE, 2023: 186-190.

致 谢

回顾四年的本科生涯，我心怀感激，在这期间我获得了许多人的帮助与支持。

首先感谢我的父母，感谢他们对我学业的支持与帮助，是我人生道路上最坚实的支柱，激励着我不断前行。

其次感谢张文胜老师和齐斌学长。他们在科研领域给予了我指导与支持，让我在学术探索的道路上不再孤单。感谢他们对我科研方向上提供的帮助。

最后，我要衷心感谢与我同行的舍友和同窗好友们。他们的友爱与真诚成就了我在大学里珍贵的回忆，我将永远铭记于心。

在此，我愿向曾经关心、支持和爱护过我的所有人们表达我最深切的谢意和最美好的祝愿。